

Esquema del Proyecto: Detección Automatizada de Paneles Solares a partir de Imágenes Térmicas de UAV

1. Contexto de la Aplicación

Problema: La inspección y el mantenimiento de parques solares a gran escala (LSPVPs) es crucial para asegurar una producción de energía óptima y maximizar el retorno de la inversión (ROI). Los métodos de inspección manual tradicionales (inspección terrestre) requieren mano de obra, consumen tiempo, son costosos y están sujetos a errores humanos (Mellit & Kalogirou, 2025). De hecho, la inspección terrestre no es apropiada para las plantas fotovoltaicas a gran escala (LSPVPs) (Mellit & Kalogirou, 2025). Esta ineficiencia puede provocar retrasos en la identificación de paneles defectuosos o de bajo rendimiento, resultando en pérdidas significativas de energía e ingresos (Mellit & Kalogirou, 2025), lo que impacta la fiabilidad y la viabilidad financiera a largo plazo (Karimzadeh Kolamroudi et al., 2025; Mellit & Kalogirou, 2025; Mohanty et al., 2025). La detección y localización de defectos es esencial para la sostenibilidad y maximización de la energía producida (Mellit & Kalogirou, 2025; Mohanty et al., 2025).

Solución: El uso de Vehículos Aéreos no Tripulados (UAVs) equipados con cámaras térmicas (imágenes termográficas IR) proporciona un método rápido, no destructivo, no invasivo y rentable para la adquisición de datos en vastas instalaciones solares (Karimzadeh Kolamroudi et al., 2025; Mellit & Kalogirou, 2025; Mohanty et al., 2025). La inspección aérea es adecuada para áreas remotas y de alto riesgo (Mellit & Kalogirou, 2025). El siguiente paso lógico es automatizar el análisis de estas imágenes, lo cual requiere el uso de técnicas de visión artificial y deep learning (DL) (Karimzadeh Kolamroudi et al., 2025; Mellit & Kalogirou, 2025; Mohanty et al., 2025). La tarea fundamental en este flujo de trabajo automatizado es la detección y localización precisa de paneles solares individuales (reconocimiento de pose) dentro de las imágenes térmicas capturadas (Luo et al., 2025). Este paso es un prerrequisito esencial para cualquier análisis posterior (Luo et al., 2025), como la detección de fallos (e.g., hotspots, el defecto más peligroso), la evaluación de anomalías visuales como la suciedad (soiling), el polvo o la arena, o el monitoreo del rendimiento (Karimzadeh Kolamroudi et al., 2025; Mellit & Kalogirou, 2025).

Impacto: Al automatizar con éxito la detección de paneles, este proyecto permitirá un sistema escalable, eficiente y fiable para el monitoreo de parques solares, utilizando herramientas de IA que pueden ser desplegadas a escala (Mohanty et al., 2025). Esto contribuye directamente a la sostenibilidad, la maximización de la producción de energía y la fiabilidad general a largo plazo de las operaciones de energía renovable (Karimzadeh Kolamroudi et al., 2025; Mellit & Kalogirou, 2025; Mohanty et al., 2025).

2. Objetivo de Machine Learning

El objetivo principal de este proyecto es desarrollar y entrenar un **modelo de detección de objetos** para identificar y localizar con precisión paneles fotovoltaicos en imágenes térmicas aéreas.

- **Modelo:** Se implementará una arquitectura de Red Neuronal Convolutiva (CNN) diseñada para la detección de objetos (por ejemplo, YOLO, SSD, Faster R-CNN).
- **Entrada:** El modelo tomará como entrada una única imagen térmica (infrarroja), capturada por un UAV.
- **Salida:** Para cada imagen de entrada, el modelo generará un conjunto de coordenadas de cajas delimitadoras [**x_min**, **y_min**, **x_max**, **y_max**] por cada panel solar que detecte, junto con una puntuación de confianza para cada detección.
- **Métrica de desempeño:** El rendimiento del modelo se evaluará utilizando métricas estándar de detección de objetos, como la precisión media promedio (*mean Average Precision*, mAP), para medir su exactitud en la localización y clasificación correctas de los paneles. Además, se analizarán las pérdidas internas del modelo para evaluar su desempeño durante el entrenamiento. La **Bounding Box Loss (box_loss)** evalúa la alineación entre las cajas predichas y las cajas reales (*ground truth*) en términos de posición, escala y relación de aspecto, utilizando la formulación de *Complete Intersection over Union* (CIoU). La **Classification Loss (cls_loss)** mide la capacidad del modelo para asignar correctamente las etiquetas de clase a cada objeto detectado, empleando la función de pérdida *Binary Cross-Entropy* (BCE). Finalmente, la **Distribution Focal Loss (dfl_loss)** refina las predicciones de los cuadros delimitadores modelando los desplazamientos de los bordes como distribuciones de probabilidad discretas y aplicando un ponderado focal para mejorar la precisión espacial de las detecciones.

3. Descripción del Dataset

El proyecto utilizará el dataset **"UAV-Based Thermal Imagery Dataset for Automated Photovoltaic Panel Detection and Fault Analysis"**, disponible en Zenodo.

- **Tipo de Dataset:** El conjunto de datos consiste en imágenes térmicas (infrarrojas) de alta resolución de paneles solares, capturadas por UAVs. Un aspecto crucial es que las imágenes están anotadas, lo que significa que la ubicación de los paneles solares ya está marcada con cajas delimitadoras, haciéndolo adecuado para el aprendizaje supervisado.
- **Tamaño:**
 - **Cantidad de Datos:** El dataset contiene más de 1,500 imágenes térmicas anotadas.
 - **Tamaño en Disco:** El tamaño total del dataset (incluyendo imágenes anotadas y no anotadas) es de aproximadamente 2.3 GB.
- **Distribución de Clases:** Para el objetivo específico de la *detección* de paneles solares, este es principalmente un problema de una sola clase.
 - **Clase:** photovoltaic_panel
 - La tarea del modelo es distinguir esta única clase de objeto del fondo (por ejemplo, suelo, estructuras de montaje, vegetación). Las anotaciones proporcionadas definirán la verdad fundamental (*ground truth*) para esta clase.

4. Resultados previos

Se cargó y pre procesó el dataset, se exploró el funcionamiento de las capas convoluciones iniciales y se construyó un modelo básico de detección de objetos. El próximo paso sería preparar

los datos de manera adecuada para entrenar este nuevo modelo Multi-Caja, lo cual implica generar las etiquetas de la cuadrícula (ground truth grid) a partir de las etiquetas originales.

La primera iteración se llevó a cabo en un notebook alojado en:

<https://colab.research.google.com/drive/1gOfsF4eC4ejLQ6gSvyeXesCdL9r2RIR5?usp=sharing>

A continuación, se presenta una secuencia visual que ilustra las etapas clave de nuestro proyecto. La primera sección muestra una selección de **imágenes representativas del dataset**, estableciendo la naturaleza de los datos de entrada. Seguidamente, se visualizan los **mapas de características** generados por una capa convolucional inicial, donde se aprecian patrones básicos como bordes y texturas. Finalmente, se exhiben los resultados del **prototipo del modelo de detección**, el cual logra localizar un panel solar mediante un **recuadro delimitador (bounding box)**.




Figura 1. Resultados iniciales del procesamiento de datos.

5. Referencias

Karimzadeh Kolamroudi, M., Jaiyeoba, O. H., Ilkan, M., & Safaei, B. (2025). A comprehensive review on the artificial intelligence for the development of thermal concentrating photovoltaic systems. *Solar Energy*, 301, 113937.

Luo, J., Wang, G., Lei, Y., Wang, D., & Zhang, H. (2025). YOLOv8n-PP: a lightweight pose recognition algorithm for photovoltaic array cleaning robot. *Journal of Real-Time Image Processing*, 22(136).

Mellit, A., & Kalogirou, S. (2025). Recent advances in the application of infrared thermographic imaging and embedded artificial intelligence for fault diagnosis and predictive maintenance of photovoltaic plants: Challenges and future directions. *Renewable and Sustainable Energy Reviews*, 223, 116057.

Mohanty, S. R., Maruf, M. U., Singh, V., & Ahmad, Z. (2025). Machine learning approaches for automatic defect detection in photovoltaic systems. *Solar Energy*, 298, 113672.

Christakakis, P., Pechlivani, E.-M., & Dimou, P. (2025). Thermal PV Panel Detection and Fault Detection Dataset for UAV-Based Inspeccion [Data set]. Zenodo.
<https://doi.org/10.5281/zenodo.16420123>