

INFORME EJECUTIVO DE PROYECTO

Detección de Paneles Solares y Análisis

Entrega 2 - Curso de Deep Learning

3 de diciembre del 2025

Resumen del alcance, arquitectura, iteraciones y resultados obtenidos en la implementación de un sistema de visión artificial para la inspección de infraestructura fotovoltaica.

1. Introducción

La inspección y el mantenimiento de sistemas fotovoltaicos resultan fundamentales para garantizar una producción de energía óptima y maximizar el retorno de la inversión (ROI). Sin embargo, los métodos tradicionales de inspección terrestre presentan limitaciones significativas: requieren gran cantidad de mano de obra, son costosos, demandan tiempo y están sujetos a errores humanos (Mellit & Kalogirou, 2025). Además, este enfoque no es adecuado para instalaciones de gran extensión, lo que retrasa la identificación de módulos defectuosos o de bajo rendimiento y genera pérdidas energéticas y económicas considerables (Mellit & Kalogirou, 2025). Estas deficiencias impactan de manera directa la fiabilidad operativa y la viabilidad financiera a largo plazo de las plantas fotovoltaicas (Karimzadeh Kolamroudi et al., 2025; Mellit & Kalogirou, 2025; Mohanty et al., 2025). Por tanto, la detección y localización temprana de fallas constituye un elemento clave para la sostenibilidad y maximización de la energía generada (Mellit & Kalogirou, 2025; Mohanty et al., 2025).

En este contexto, el uso de vehículos aéreos no tripulados (UAVs) equipados con cámaras termográficas se ha consolidado como una alternativa eficaz para la adquisición rápida, no destructiva y rentable de datos en extensas instalaciones solares (Karimzadeh Kolamroudi et al., 2025; Mellit & Kalogirou, 2025; Mohanty et al., 2025). La inspección aérea permite cubrir áreas remotas o de difícil acceso con una alta resolución espacial y temporal (Mellit & Kalogirou, 2025). No obstante, el verdadero potencial de esta tecnología se alcanza mediante la automatización del análisis de imágenes térmicas, apoyada en técnicas de visión por computador y aprendizaje profundo (Deep Learning) (Karimzadeh Kolamroudi et al., 2025; Mohanty et al., 2025). Dentro de este flujo de trabajo automatizado, la tarea esencial consiste en la detección y localización precisa de los módulos fotovoltaicos individuales dentro de las imágenes capturadas (Luo et al., 2025), lo cual es un prerrequisito indispensable para etapas posteriores como la identificación de fallas (por ejemplo, *hotspots*), la evaluación de anomalías visuales —suciedad, polvo o degradación superficial— y el monitoreo del rendimiento general del sistema (Karimzadeh Kolamroudi et al., 2025; Mellit & Kalogirou, 2025).

En este marco, el presente proyecto explora la implementación de las arquitecturas YOLOv8 y YOLOv11, realizando un proceso de fine-tuning sobre modelos preentrenados con el propósito de realizar la detección de módulos fotovoltaicos y desarrollar una herramienta que abarque todo el *pipeline* de detección automática de fallas en sistemas fotovoltaicos. Además, busca complementar y validar el modelo previamente desarrollado por el grupo de investigación para la detección de anomalías en paneles solares (Jiménez, 2025). La integración de cámaras termográficas en UAVs y sistemas de monitoreo fijo basados en plataformas embebidas posibilita la adquisición masiva y sistemática de imágenes térmicas, abriendo nuevas oportunidades para el diagnóstico temprano, la optimización de mantenimiento predictivo y la mejora continua del desempeño energético de los sistemas fotovoltaicos.

2. Estructura del Notebook

El *notebook* se estructura en dos secciones. En la primera se carga el *dataset* "**UAV-Based Thermal Imagery Dataset for Automated Photovoltaic Panel Detection and Fault Analysis**". Este conjunto de datos, accesible a través de un archivo compartido en Drive y proveniente del repositorio Zenodo. Una vez cargado, se procede a la organización de las imágenes y sus correspondientes etiquetas, siguiendo las directrices recomendadas por *Ultralytics*. La reorganización establece una estructura jerárquica para el conjunto de datos, con directorios de imágenes y etiquetas, cada uno con subdirectorios *train*, *val* y *test*. Este conjunto de datos consta de 353 termografías (640 x 512 píxeles), procesadas para evitar superposiciones, que agrupan un total masivo de 26,678 instancias de paneles fotovoltaicos anotadas. El problema se define como detección de objetos de clase única (*photovoltaic_panel*), con una distribución de datos estratificada en entrenamiento (235 imágenes), validación (83) y prueba (35).




Figura 1. Estructura del dataset y visualización de los paneles solares, sus respectivos bounding boxes

La segunda sección corresponde a la afinación de las dos arquitecturas de YOLO (YOLOv8n y YOLOv11n, en sus variantes nano) respectivamente. Se inicia con la creación del archivo de configuración *data.yaml*, el cual especifica la ruta del dataset y la distribución de los conjuntos de entrenamiento, validación y prueba, además de definir las clases de objetos a detectar (en este caso, un único objeto 'pv'). Posteriormente, se cargan los modelos preentrenados y se ejecuta un proceso de *fine-tuning* para adaptar sus pesos al dataset específico. Ambos modelos fueron entrenados durante 10 épocas, utilizando un tamaño de imagen de 640 píxeles. Durante este proceso, se generaron métricas de rendimiento como mAP50 y mAP50-95, las cuales fueron visualizadas mediante curvas de entrenamiento y y

matrices de confusión para evaluar la convergencia y el desempeño. Finalmente, se realizaron predicciones sobre el conjunto de prueba y en imágenes externas para demostrar la capacidad de generalización de los modelos afinados, incluyendo una visualización comparativa de las *ground truth* y las predicciones, así como un análisis de los mapas de características de las diferentes capas del modelo. Una comparación del rendimiento de mAP50 y mAP50-95 de ambos modelos es presentada al final de la sección para determinar cuál de las arquitecturas ofrece un mejor desempeño en este contexto.

3. Descripción de las Arquitectura de los modelos de detección.

Las arquitecturas YOLO (*You Only Look Once*) empleadas representan la evolución del estado del arte en detectores de una sola etapa (*one-stage detectors*), caracterizados por realizar la predicción de clases y cajas delimitadoras en una única pasada de la red neuronal. Ambas arquitecturas se componen de tres partes principales. El **Backbone**, donde todo comienza y es responsable de analizar los datos crudos de las imágenes al extraer los patrones significativos. Las capas iniciales extraer detalles como bordes, texturas y formas simples, mientras capas más profundas capturan rasgos semánticos de mayor complejidad asociados a la forma y contexto de los objetos. De manera metafóricamente se puede pensar el backbone como los ojos del modelo.

Posteriormente, nos encontramos con el **Neck**, combinando o fusionando las características provenientes de la etapa anterior, mediante estructuras como FPN (*Feature Pyramid Network*) o PAN (*Path Aggregation Network*). Este proceso preserva detalles espaciales y enriquece la información contextual, permitiendo una detección más robusta frente a variaciones de tamaño, iluminación o perspectiva. Finalmente, el **Head** se encarga de generar las predicciones: interpreta las características refinadas por el neck para estimar las **coordenadas de las cajas delimitadoras (bounding boxes)**, los **puntajes de confianza** y las **probabilidades de clase** de cada objeto presente en la escena. Esta arquitectura permite que YOLO ejecute la detección en tiempo real con alta precisión.

YOLOv8 (Figura 2a) introdujo un paradigma *anchor-free*, reemplazando los cuadros de anclaje tradicionales por un esquema de predicción directa de coordenadas, simplificando el entrenamiento y mejorando la adaptabilidad a objetos de diferentes escalas. Su arquitectura, basada en convoluciones CSP-Darknet y optimizada con bloques C2f (fusión de múltiples características), reduce el costo computacional sin sacrificar rendimiento, mientras que su estructura PAN-FPN híbrida en el Neck refuerza la fusión de características multi-escala. Por su parte, YOLOv11 (Figura 2a) representa una evolución orientada a maximizar el equilibrio entre velocidad y precisión, Esto se logró reemplazando los bloques C2f por los bloques compactos C3k2 e integrando un módulo C2PSA para fortalecer la atención espacial. Esta optimización estructural se refleja en las variantes Nano (n): mientras que YOLOv8n utiliza 3.2 millones de parámetros y 8.7 GFLOPs, el modelo YOLO11n (con 2.6 millones de parámetros y 6.5

GFLOPs) consigue una operación más eficiente por inferencia, validando el diseño modular más depurado de la versión 11 (Sapkota & Karkee, 2025)




Figure 4: YOLOv8 architecture diagram

a. Arquitectura YOLOv8




Figure 3: YOLO11 architecture diagram

b. Arquitectura YOLO11

Figura 2. Arquitectura de las versiones 8 y 11 de YOLO (Sapkota & Karkee, 2025).

4. Descripción de las iteraciones y resultados

Se realizaron dos iteraciones, para afinar las arquitecturas **YOLOv8n** y **YOLOv11n** con el objetivo de optimizar la detección de paneles fotovoltaicos. En la **primera iteración**, se empleó el modelo preentrenado **YOLOv8n.pt**, configurando el archivo **data.yaml** con una estructura reorganizada del conjunto de datos y una única clase denominada *pv*. El entrenamiento se desarrolló durante **10 épocas**, con un tamaño de imagen (**imgsz**) de **640 píxeles**, **batch size** por defecto de **16** y el optimizador **AdamW**. El modelo alcanzó métricas de desempeño destacadas (**mAP50** $\approx$ **0.984** y **mAP50-95** $\approx$ **0.86**), evidenciando una convergencia estable y una alta precisión en la detección. En la **segunda iteración**, se utilizó el modelo **YOLOv11n.pt** manteniendo el mismo archivo de configuración y los mismos hiperparámetros. Este modelo mostró resultados similares, con **mAP50** $\approx$ **0.985** y **mAP50-95** $\approx$ **0.858**. Las gráficas de resultados y matrices de confusión se muestran en las Figuras 3, 4 y 5 reflejaron una evolución del ajuste en ambas versiones, demostrando un comportamiento eficaz en la detección de apaneles fotovoltaicos.




Figura 3. (a) Precision promedio de las detecciones del modelo para IoU > 0.5 y (b) precision promedio para el umbral $0.5 < \text{IoU} < 0.95$.




Figura 4. Resultados afinación de arquitectura YOLOv8 (a) y YOLOv11 (b).

A continuación se describe las tendencias mostradas en la figura 4. La métrica `box_loss` cuantifica el error asociado a la regresión de las coordenadas y dimensiones de las cajas delimitadoras. En ambas arquitecturas evaluadas, se observa una tendencia descendente, tanto en la fase de entrenamiento como en la de validación, a medida que progresan las épocas. Este comportamiento evidencia un refinamiento efectivo en la localización espacial de los objetos. Asimismo, la convergencia simultánea de las curvas de validación y entrenamiento sugiere una capacidad de generalización adecuada, descartando la presencia de sobreajuste (*overfitting*) en la predicción geométrica. Similar a la anterior métrica, la pérdida de clase también presenta una tendencia descendente en ambas, la cual se estabiliza cerca a 0.5. `dfl_loss` presenta también una tendencia decreciente, produciéndose en el entrenamiento un decaimiento más brusco que para validación, sin embargo, la validación en el modelo yolo11 oscila un poco más.

A continuación, se describen las dinámicas de aprendizaje ilustradas en la Figura 4. La métrica `box_loss` cuantifica el error en la regresión de coordenadas; para ambas arquitecturas, se observa una tendencia descendente tanto en entrenamiento como en validación, evidenciando un refinamiento en la localización espacial y descartando problemas de sobreajuste. De manera análoga, la pérdida de clasificación (`cls_loss`) exhibe una reducción que converge hacia un valor de 0.5. Por último, el `dfl_loss` revela una disminución, el entrenamiento presenta un decaimiento más acentuado que la validación. Cabe destacar que, en el modelo YOLO11, la

curva de validación de esta métrica muestra fluctuaciones más marcadas, sin comprometer la tendencia global de optimización.





Figura 5. Matriz de confusión después del ajuste de la arquitectura YOLOv8 (a) y YOLOv11.

La **Figura 5** ilustra las matrices de confusión resultantes, permitiendo visualizar el desempeño de clasificación de los objetos detectados. En ambas arquitecturas, se evidencia una alta cantidad de **verdaderos positivos**, concentrados en la diagonal principal. Este patrón indica una alta sensibilidad en los modelos, confirmando que la gran mayoría de los paneles fotovoltaicos presentes en las imágenes de validación fueron identificados correctamente, con una tasa mínima de falsos negativos



a. Predicción de imagen de prueba para la arquitectura YOLOv8.

b. Predicción de imagen de prueba para la arquitectura YOLOv11.

Figura 6. Predicción realizada a imágenes de prueba de manera aleatoria.

La **Figura 6** muestra la predicción de una imagen aleatoria de prueba no vista previamente por ninguna de las dos arquitecturas, YOLOv8 y YOLOv11, durante la fase de entrenamiento. En la visualización, los bounding boxes anotados en el conjunto de datos se representan en color verde, mientras que las predicciones del modelo aparecen en color rojo. Se observa una

Con el fin de evaluar el desempeño del modelo en condiciones distintas a las del conjunto de entrenamiento, se utilizaron dos imágenes externas: una termográfica, obtenida en el laboratorio de paneles solares de la estación solar SIU, y otra correspondiente a paneles instalados en un techo residencial. En la primera imagen, la arquitectura YOLOv8 logró detectar un panel, aunque la mayoría de los bounding boxes se concentraron sobre la superficie del panel inferior derecho, sin coincidir con las delimitaciones correctas. En contraste, en la imagen del techo residencial se observaron más detecciones y una mejor ubicación de las cajas sobre los paneles solares, reflejando un rendimiento más favorable. Por su parte, la arquitectura YOLOv11 mostró una menor cantidad de detecciones en ambos casos, lo que sugiere un comportamiento menos consistente bajo estas condiciones. En conjunto, los resultados indican que ninguno de los modelos alcanzó un desempeño óptimo ante imágenes con características térmicas y contextos diferentes a los del entrenamiento. Esta limitación es debida a la escasa representación de escenarios similares en el dataset original, por lo que se planea ampliar y diversificar el conjunto de datos para mejorar la capacidad de generalización y avanzar hacia una futura etapa de segmentación de paneles solares.

Referencias

Christakakis, P., Pechlivani, E.-M., & Dimou, P. (2025). Thermal PV Panel Detection and Fault Detection Dataset for UAV-Based Inspeccion [Data set]. Zenodo.
<https://doi.org/10.5281/zenodo.16420123>

Electric Power Research Institute (EPRI). (2017). *Technical Update: Arc Flash Hazards and Protection Strategies in Renewable Energy Applications, Including Batteries and Fuel Cells* (Product ID 3002012582). Electric Power Research Institute.
<https://www.epri.com/research/products/000000003002012582>

Jimenez, K., Cano, J. B., & Velilla, E. (2026). A lightweight deep learning model for fault detection of PV modules using thermal images. *Solar Energy*, 303, 114120.
<https://doi.org/10.1016/j.solener.2025.114120>

Karimzadeh Kolamroudi, M., Jaiyeoba, O. H., Ilkan, M., & Safaei, B. (2025). A comprehensive review on the artificial intelligence for the development of thermal concentrating photovoltaic systems. *Solar Energy*, 301, 113937.

Luo, J., Wang, G., Lei, Y., Wang, D., & Zhang, H. (2025). YOLOv8n-PP: a lightweight pose recognition algorithm for photovoltaic array cleaning robot. *Journal of Real-Time Image Processing*, 22(136).

Mellit, A., & Kalogirou, S. (2025). Recent advances in the application of infrared thermographic imaging and embedded artificial intelligence for fault diagnosis and predictive maintenance of photovoltaic plants: Challenges and future directions. *Renewable and Sustainable Energy Reviews*, 223, 116057.

Mohanty, S. R., Maruf, M. U., Singh, V., & Ahmad, Z. (2025). Machine learning approaches for automatic defect detection in photovoltaic systems. *Solar Energy*, 298, 113672.

Roca, R. (2024, 6 de junio). *Más de 1.000 incendios se produjeron en instalaciones fotovoltaicas en los últimos dos años*. El Periódico de la Energía.
<https://elperiodicodelaenergia.com/mas-de-1-000-incendios-se-produjeron-en-instalaciones-fotovoltaicas-en-los-ultimos-dos-anos/>

Sapkota, R., & Karkee, M. (2025, 16 de octubre). ULTRALYTICS YOLO EVOLUTION: AN OVERVIEW OF YOLO26, YOLO11, YOLOV8, AND YOLOV5 OBJECT DETECTORS FOR COMPUTER VISION AND PATTERN RECOGNITION. (Manuscrito no publicado)

TÜV Rheinland Energie und Umwelt GmbH & Fraunhofer-Institut für Solare Energiesysteme (ISE). (2018). *Assessing Fire Risks in Photovoltaic Systems and Developing Safety Concepts for Risk Minimization* (Guideline). U.S. Department of Energy.
https://www.energy.gov/sites/default/files/2018/10/f56/PV%20Fire%20Safety%20Fire%20Guideline_Translation_V04%2020180614_FINAL.pdf